



RÉPUBLIQUE TOGOLAISE

TRAVAIL - LIBERTÉ - PATRIE

MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR ET DE LA RECHERCHE

UNIVERSITÉ DE LOMÉ — ÉCOLE POLYTECHNIQUE DE LOMÉ

RAPPORT DE STAGE DE FIN DE FORMATION

Domaine : Sciences et Technologies

Parcours : Licence Fondamentale

Mention : Sciences de l'Ingénieur

Spécialité : Intelligence Artificielle et Big Data

Thème :

DÉVELOPPEMENT D'UN PIPELINE MODULAIRE POUR LA PRÉPARATION ET L'ANALYSE DES IMAGES MÉDICALES DU CANCER DU SEIN

Projet soumis par :

TETTEH ASSIAKOLEY S.M. Clément
AMAH-TCHOUTCHOU Elikplim Josué
NADJAK Moyinib Pierre Damien

Directeur de mémoire :

Dr Séna APEKE
Enseignant à l'École Polytechnique de Lomé

Année universitaire : 2025 – 2026

Remerciements

Avant tout, nous rendons grâce à Dieu, le Tout-Puissant, pour la vie, la santé, la force et la sagesse qu’Il nous a accordées tout au long de notre parcours académique et durant la réalisation de ce projet. Que toute la gloire Lui revienne.

Nous adressons nos plus sincères remerciements à notre encadrant, **Dr Séna APEKE**, enseignant-chercheur à l’École Polytechnique de Lomé, pour la confiance qu’il nous a accordée, la vision qu’il a insufflée à ce projet, sa disponibilité, sa rigueur scientifique ainsi que ses précieux conseils. Son accompagnement et son exigence ont constitué une source permanente de motivation et ont grandement contribué à l’aboutissement de ce travail.

Nous exprimons également notre profonde gratitude à l’ensemble du corps enseignant et du personnel administratif de **l’École Polytechnique de Lomé**, pour la qualité de la formation dispensée, les connaissances transmises et les conditions d’apprentissage mises à notre disposition tout au long de notre cursus.

Nous adressons une pensée toute particulière à nos parents et à nos familles, dont le soutien moral, les sacrifices, les encouragements constants et la confiance ont rendu possible la poursuite de nos études. Leur présence à nos côtés a été une source inestimable de force et de persévérance.

Nous remercions également tous nos camarades, amis et toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce projet, par leurs conseils, leurs encouragements ou leur disponibilité.

Enfin, nous formulons le vœu que ce travail puisse, à son humble niveau, contribuer à l’amélioration de l’analyse des images médicales et au développement de solutions innovantes fondées sur l’intelligence artificielle au service de la santé, notamment au Togo.

À toutes ces personnes, nous adressons nos plus sincères remerciements.

Résumé

L'analyse d'images médicales joue un rôle crucial dans le diagnostic, le suivi des traitements et la recherche contre le cancer du sein. Cela dit, face à la multiplicité des formats, des protocoles d'acquisition et des modalités d'imagerie, une étape s'impose avant de lancer la moindre analyse radiomique ou d'entraîner un modèle d'intelligence artificielle : il faut bâtir une chaîne de préparation des données qui soit à la fois fiable, standardisée et parfaitement reproductible.

C'est précisément l'objectif de ce travail : concevoir une pipeline modulaire pensée pour nettoyer, structurer et analyser les images médicales liées au cancer du sein. Pour nos expérimentations, nous sommes partis du jeu de données **I-SPY 2** (*Investigation of Serial Studies to Predict Your Therapeutic Response with Imaging and Molecular Analysis 2*). Les images au format **DICOM** sont d'abord extraites puis converties au format **NIfTI**, avant d'être organisées selon l'architecture **BIRDS** (*Breast Imaging Research Data Structure*). Cette organisation rigoureuse garantit une structuration cohérente des données et facilite la reproductibilité des analyses.

Au cœur du projet, la bibliothèque logicielle développée regroupe l'ensemble des traitements nécessaires à la préparation des images médicales : correction d'intensité, normalisation, débruitage, rehaussement de contraste, détection de contours, morphologie mathématique et segmentation. Une fois ces opérations effectuées, les caractéristiques radiomiques sont extraites puis soumises à une analyse statistique approfondie afin d'évaluer l'influence des différentes techniques de prétraitement sur la qualité, la stabilité et le pouvoir descriptif des caractéristiques obtenues.

En reliant directement l'extraction des données à l'analyse radiomique, cette pipeline propose une solution complète couvrant l'ensemble de la chaîne de préparation des données d'imagerie médicale. Son architecture modulaire favorise la réutilisation des composants, facilite la conduite de nouvelles expérimentations et permet l'intégration de futurs algorithmes. Elle constitue ainsi une base robuste pour le développement de solutions d'intelligence artificielle appliquées à l'analyse des images médicales du cancer du sein.

Abstract

Medical image analysis plays a fundamental role in the diagnosis, treatment monitoring, and research of breast cancer. However, the diversity of imaging modalities, acquisition protocols, and data formats requires the establishment of a reliable, standardized, and reproducible data preparation workflow before any radiomic analysis or artificial intelligence application can be performed.

This work presents the development of a modular pipeline designed to prepare, organize, and analyze breast medical images. The proposed framework is built upon the **I-SPY 2** (*Investigation of Serial Studies to Predict Your Therapeutic Response with Imaging and Molecular Analysis 2*) dataset. Medical images are first extracted from the dataset, converted from the **DICOM** format to **NIfTI**, and subsequently organized according to the **Breast Imaging Research Data Structure (BIRDS)** architecture to ensure consistent data management and reproducible experiments.

At the core of this work is a modular software library that integrates a comprehensive collection of medical image preprocessing techniques, including intensity correction, normalization, denoising, contrast enhancement, edge detection, mathematical morphology, and image segmentation. Following the preprocessing stage, radiomic features are extracted and statistically analyzed to assess the impact of each preprocessing technique on the quality, stability, and descriptive power of the extracted features.

By covering the entire workflow from data extraction and organization to radiomic feature analysis the proposed pipeline provides a complete, reusable, and extensible framework for medical image processing. Its modular architecture promotes reproducible research, facilitates the integration of new preprocessing methods, and establishes a robust foundation for the future development of artificial intelligence applications in breast cancer imaging.

Table des matières

Remerciements	1
Résumé	2
Abstract	3
Liste des figures	6
Liste des tableaux	7
Liste des abréviations	8
Introduction générale	9
1 ÉTUDE PRÉALABLE DU SUJET	10
1.1 Présentation du domaine d'étude	11
1.1.1 Le cancer du sein : contexte et enjeux	11
1.1.2 L'imagerie par résonance magnétique (IRM) dans le diagnostic du cancer du sein	12
1.1.3 Radiomique et analyse quantitative des images médicales	12
1.1.4 Les pipelines d'analyse des images médicales	13
1.2 Problématique du sujet	14
1.2.1 Hétérogénéité des données d'imagerie médicale	14
1.2.2 Gestion des données médicales	15
1.2.3 Influence du prétraitement sur les caractéristiques radiomiques	15
1.2.4 Besoin d'une pipeline modulaire et reproductible	15
1.3 Intérêt de l'étude	15
1.3.1 Intérêt scientifique	16
1.3.2 Intérêt technique	16
1.3.3 Intérêt applicatif	16
1.4 Objectifs du projet	16
1.4.1 Objectif général	16
1.4.2 Objectifs spécifiques	16
1.5 Revue de la littérature	17
1.5.1 Formats et organisation des données	17
1.5.2 Méthodes de prétraitement et extraction radiomique	17

1.5.3	Limites des approches existantes	17
1.5.4	Solution proposée	17
	Conclusion du chapitre	18
2	Matériels et Méthodes	19
2.1	Présentation générale	19
2.2	Matériels	20
2.2.1	Jeu de données I-SPY 2	20
2.2.2	Organisation des données	21
2.2.3	Environnement de développement	22
2.2.4	Environnement matériel	22
2.3	Conception de la pipeline	23
2.3.1	Architecture générale	23
2.3.2	Architecture logicielle et packages	23
2.3.3	Principes architecturaux et choix de conception	24
2.4	Modules de la pipeline	24
2.4.1	Extraction des données	24
2.4.2	Conversion DICOM $\rightarrow$ NIfTI	24
2.4.3	Organisation des données selon BIDS	25
2.4.4	Bibliothèque de prétraitement	25
2.5	Méthodes de prétraitement	25
2.5.1	Correction d'intensité et normalisation	25
2.5.2	Amélioration du contraste	26
2.5.3	Réduction du bruit	27
2.5.4	Détection de contours	27
2.5.5	Morphologie mathématique	28
2.5.6	Segmentation des régions d'intérêt	28
2.5.7	Post-traitement et évaluation des masques	29
2.6	Extraction des caractéristiques radiomiques	30
2.6.1	Principe et utilisation de PyRadiomics	30
2.6.2	Catégories de caractéristiques radiomiques	31
2.7	Analyse statistique	31
2.7.1	Indicateurs de qualité et de stabilité	31
2.7.2	Tests statistiques et comparaison des méthodes	32
	Conclusion du chapitre	32

Table des figures

1.1	Pipeline générale d'analyse des images médicales.	14
1.2	Architecture modulaire de la pipeline proposée.	18
2.1	Illustration du jeu de données I-SPY 2 et des acquisitions IRM utilisées.	21
2.2	Organisation des données selon une structure inspirée de BIDS.	22
2.3	Principe général de l'extraction radiomique avec PyRadiomics.	30

Liste des tableaux

2.1	Principales caractéristiques du jeu de données I-SPY 2.	20
2.2	Principales bibliothèques logicielles utilisées.	22
2.3	Environnement matériel utilisé.	23
2.4	Comparaison des méthodes de correction d'intensité et de normalisation	26
2.5	Comparaison des méthodes d'amélioration du contraste	27
2.6	Comparaison des méthodes de réduction du bruit	27
2.7	Comparaison des méthodes de détection de contours	28
2.8	Synthèse des opérations morphologiques implémentées	28
2.9	Comparaison des méthodes de segmentation	29
2.10	Synthèse des opérations de post-traitement et métriques	30
2.11	Principales familles de caractéristiques radiomiques extraites.	31
2.12	Indicateurs de qualité et de stabilité des caractéristiques radiomiques	32
2.13	Objectifs de la comparaison statistique	32

Liste des abréviations

Abréviation	Signification
CNN	Convolutional Neural Network (Réseau de neurones convolutif)
ROI	Region of Interest (Région d'intérêt)
CAD	Computer-Aided Detection (Détection assistée par ordinateur)
MRI	Magnetic Resonance Imaging (Imagerie par résonance magnétique)
NLP	Natural Language Processing (Traitement automatique du langage naturel)
GLCM	Gray Level Co-occurrence Matrix (Matrice de co-occurrence des niveaux de gris)
<i>[Ajoutez ici vos autres abréviations selon vos besoins]</i>	

Introduction générale

Le cancer du sein constitue l'un des enjeux de santé publique les plus préoccupants à l'échelle mondiale. Selon les estimations de GLOBOCAN 2024, environ 2,4 millions de nouveaux cas sont diagnostiqués chaque année, et près de 694 000 décès lui sont imputables, ce qui en fait l'un des cancers les plus meurtriers chez la femme (Sung et al., 2026). Malgré les progrès du dépistage et des thérapies, améliorer le diagnostic, mieux prédire la réponse aux traitements et personnaliser la prise en charge demeurent des défis majeurs.

Dans ce contexte, l'imagerie médicale, et en particulier l'imagerie par résonance magnétique (IRM), joue un rôle central en fournissant des informations anatomiques et fonctionnelles détaillées sur les tumeurs mammaires. Au-delà de l'interprétation visuelle, ces images sont devenues une source de données quantitatives grâce à la radiomique, qui extrait automatiquement de nombreuses caractéristiques décrivant le phénotype radiologique des lésions (Lambin et al., 2012). Toutefois, l'exploitation fiable de ces données exige des chaînes de traitement rigoureuses, car les images brutes (souvent au format DICOM) présentent une forte hétérogénéité liée aux équipements, aux protocoles d'acquisition et aux paramètres de reconstruction. Des étapes préalables de conversion, d'organisation et de prétraitement sont donc indispensables pour garantir des analyses reproductibles.

C'est précisément l'objectif de ce projet : développer une pipeline modulaire dédiée à la préparation et à l'analyse des images IRM du cancer du sein, en s'appuyant sur le jeu de données I-SPY 2 (*Investigation of Serial Studies to Predict Your Therapeutic Response with Imaging and Molecular Analysis 2*) (Wang et al., 2017). Les données sont extraites automatiquement, converties du format DICOM vers le format NIfTI, puis organisées selon une structure inspirée du standard BIDS (*Brain Imaging Data Structure*) et adaptée à l'imagerie mammaire. Cette organisation facilite la traçabilité et la reproductibilité des expérimentations.

La solution intègre également une bibliothèque modulaire regroupant diverses méthodes de prétraitement (correction d'intensité, normalisation, débruitage, amélioration du contraste, segmentation, etc.). Après application de ces traitements, les caractéristiques radiomiques sont extraites avec des outils tels que PyRadiomics (Van Griethuysen et al., 2017), puis analysées statistiquement pour évaluer l'influence de chaque stratégie de prétraitement sur leur qualité et leur stabilité.

Ce rapport présente la conception, l'implémentation et l'évaluation de cette pipeline en trois chapitres : le premier expose le contexte, la problématique et la revue de la littérature ; le deuxième détaille les matériels et méthodes ; le troisième analyse et discute les résultats obtenus.

CHAPITRE 1 ÉTUDE PRÉALABLE DU SUJET

Ce premier chapitre présente le contexte scientifique et technique dans lequel s’inscrit ce projet. Il introduit les notions fondamentales relatives au cancer du sein, à l’imagerie par résonance magnétique (IRM) et à la radiomique, avant d’aborder les problématiques liées à la préparation des données médicales en vue d’une analyse quantitative. Une revue de la littérature est ensuite réalisée afin d’identifier les principales approches existantes, leurs limites ainsi que les lacunes auxquelles ce travail apporte une contribution.

1.1 Présentation du domaine d’étude

Le cancer du sein demeure un enjeu majeur de santé publique. L’imagerie par résonance magnétique (IRM) y occupe une place essentielle grâce à sa capacité à fournir des informations anatomiques et fonctionnelles détaillées, permettant une détection et une caractérisation précises des lésions tumorales (StatPearls, 2024).

Au-delà de l’interprétation visuelle, les progrès du traitement numérique des images ont ouvert la voie à la **radiomique**, qui extrait automatiquement de nombreuses caractéristiques quantitatives décrivant la morphologie, la texture et les propriétés statistiques des tissus. Cette approche offre des perspectives nouvelles pour l’étude des tumeurs et l’identification de biomarqueurs d’imagerie (Lambin et al., 2012).

Cependant, la fiabilité de ces caractéristiques dépend fortement des traitements appliqués aux images avant leur extraction. Les variations liées aux appareils, aux protocoles d’acquisition et aux formats de stockage introduisent une variabilité qui peut compromettre la reproductibilité des analyses. Il est donc indispensable de mettre en œuvre une chaîne de préparation rigoureuse, couvrant l’extraction, la conversion, l’organisation et le prétraitement des données (Demircioğlu, 2025).

Ce travail s’inscrit dans cette perspective en développant une **pipeline modulaire** dédiée à l’analyse quantitative d’images IRM du cancer du sein. S’appuyant sur le jeu de données **I-SPY 2** (*Investigation of Serial Studies to Predict Your Therapeutic Response with Imaging and Molecular Analysis 2*), la pipeline assure l’extraction automatique des examens, leur conversion du format **DICOM** vers **NIfTI** et leur organisation selon une structure de données inspirée du standard **BIDS** (*Brain Imaging Data Structure*), adaptée à l’imagerie mammaire. Elle intègre également une bibliothèque de prétraitement modulaire, l’extraction de caractéristiques radiomiques et une analyse statistique comparative de ces dernières (Wang et al., 2017).

1.1.1 Le cancer du sein : contexte et enjeux

Le cancer du sein est une prolifération incontrôlée de cellules anormales dans les tissus mammaires, le plus souvent au niveau des canaux galactophores (carcinome canalaire) ou des lobules (carcinome lobulaire). Il s’agit d’une maladie hétérogène dont le pronostic dépend du type histologique, du stade clinique et des caractéristiques moléculaires. Avec environ 2,4 millions de nouveaux cas et 694 000 décès par an, il représente le cancer féminin le plus fréquent et l’une des principales causes de mortalité (Sung et al., 2026).

Son développement résulte de l'interaction de facteurs génétiques (mutations *BRCA1/2*), hormonaux, environnementaux et comportementaux (obésité, alcool, sédentarité). Cependant, de nombreuses patientes ne présentent aucun facteur de risque majeur, ce qui renforce la nécessité d'un dépistage précoce et d'outils d'aide au diagnostic performants ([Organisation Mondiale de la Santé, 2026](#)).

Le diagnostic associe examen clinique, imagerie (mammographie, échographie, IRM) et analyse anatomopathologique. La mammographie est l'examen de référence pour le dépistage, tandis que l'IRM est privilégiée chez les patientes à risque élevé ou présentant des seins denses. Ces modalités permettent non seulement de détecter les lésions, mais aussi de guider les décisions thérapeutiques et d'assurer le suivi.

L'analyse quantitative des images est venue enrichir ce panel en extrayant automatiquement des caractéristiques morphologiques, texturales et fonctionnelles des tumeurs. Cette évolution ouvre la voie à des biomarqueurs d'imagerie plus objectifs, à condition de disposer de données de qualité, ce qui exige des procédures rigoureuses de préparation et de prétraitement.

1.1.2 L'imagerie par résonance magnétique (IRM) dans le diagnostic du cancer du sein

L'IRM est une modalité d'imagerie non irradiante qui exploite les propriétés magnétiques des noyaux d'hydrogène pour produire des images tridimensionnelles à haut contraste des tissus mous. Dans le cancer du sein, elle complète la mammographie et l'échographie, notamment pour les patientes à risque élevé, les seins denses, le bilan d'extension locorégionale ou l'évaluation de la réponse aux traitements néoadjuvants ([StatPearls, 2024](#)).

L'IRM dynamique avec injection de produit de contraste (DCE-MRI) apporte des informations fonctionnelles sur la vascularisation et la perfusion tumorales, essentielles pour la caractérisation des lésions. Le jeu de données **I-SPY 2**, utilisé dans ce projet, est principalement constitué d'images DCE-MRI acquises chez des patientes atteintes d'un cancer du sein localement avancé, dans le cadre d'un essai multicentrique visant à identifier précocement les réponses aux nouvelles thérapies ([Wang et al., 2017](#)).

Cependant, les images IRM sont sujettes à diverses sources de variabilité (inhomogénéités du champ, bruit, différences inter-constructeurs, protocoles d'acquisition) qui affectent la reproductibilité des analyses quantitatives. Une préparation rigoureuse est donc indispensable : conversion du format DICOM vers NIfTI, organisation structurée des données, correction d'intensité, normalisation et débruitage. Ces étapes, au cœur de la pipeline développée, conditionnent la qualité des caractéristiques radiomiques extraites.

1.1.3 Radiomique et analyse quantitative des images médicales

La **radiomique** consiste à extraire automatiquement, à partir des images médicales, un grand nombre de caractéristiques quantitatives décrivant la morphologie, l'intensité et la texture des tissus. Ces caractéristiques, imperceptibles à l'œil nu, reflètent potentiellement les propriétés biologiques

sous-jacentes des lésions et constituent des biomarqueurs d'imagerie (Lambin et al., 2012).

On distingue plusieurs familles : les caractéristiques de premier ordre (distribution des intensités), de forme (géométrie de la lésion) et de texture (relations spatiales entre voxels), auxquelles s'ajoutent des caractéristiques dérivées après filtrage (ondelettes, Laplacien de Gaussienne) (Van Griethuysen et al., 2017). Ces descripteurs sont utilisés en oncologie pour caractériser l'hétérogénéité tumorale et rechercher des corrélations avec les données cliniques ou génomiques.

Cependant, les valeurs radiomiques sont très sensibles aux conditions d'acquisition et aux traitements appliqués aux images. Bruit, inhomogénéités d'intensité, différences de protocole ou de résolution peuvent altérer les caractéristiques extraites et compromettre la reproductibilité des études (Demircioğlu, 2025). Une préparation rigoureuse est donc indispensable : correction d'intensité, normalisation, débruitage, amélioration du contraste et segmentation des régions d'intérêt.

Dans ce projet, après conversion des images au format NIfTI et organisation selon une structure inspirée de BIDS, les prétraitements sont appliqués puis les caractéristiques radiomiques extraites à l'aide de **PyRadiomics**. Une analyse statistique comparative permet ensuite d'évaluer l'impact de chaque méthode de prétraitement sur la qualité et la stabilité des caractéristiques obtenues.

1.1.4 Les pipelines d'analyse des images médicales

Une **pipeline d'analyse** désigne une chaîne de traitement automatisée qui transforme les images médicales brutes en données quantitatives exploitables, tout en garantissant reproductibilité et traçabilité. Les données, initialement au format **DICOM**, sont converties en **NIfTI** puis organisées selon une structure standardisée (inspirée de **BIDS**) avant de subir les opérations de prétraitement, de segmentation et d'extraction des caractéristiques radiomiques. La Figure 1.1 illustre ce séquençement typique.




FIG. 1.1 : Pipeline générale d'analyse des images médicales.

Malgré l'existence d'outils spécialisés, la mise en œuvre d'une pipeline complète reste complexe : les étapes s'appuient souvent sur des logiciels indépendants, sans intégration native, ce qui nuit à la reproductibilité. De plus, les caractéristiques radiomiques sont très sensibles aux choix de prétraitement (normalisation, débruitage, etc.), d'où la nécessité de disposer d'une chaîne homogène permettant de comparer objectivement différentes stratégies (IBSI, 2020).

C'est précisément l'approche retenue dans ce travail : la pipeline développée automatise l'ensemble du processus — extraction depuis I-SPY 2, conversion, organisation et prétraitement — jusqu'à l'analyse statistique des caractéristiques radiomiques, dans un cadre modulaire et reproductible.

1.2 Problématique du sujet

L'analyse radiomique repose sur l'hypothèse que les caractéristiques quantitatives extraites des images IRM reflètent les propriétés biologiques des tumeurs. Cependant, la reproductibilité de ces biomarqueurs est compromise par de nombreuses sources de variabilité : protocoles d'acquisition, équipements, formats de stockage et étapes de prétraitement. Disposer d'une pipeline standardisée et modulaire devient donc indispensable pour maîtriser ces variations et évaluer objectivement l'impact du prétraitement sur les caractéristiques radiomiques.

1.2.1 Hétérogénéité des données d'imagerie médicale

Les images IRM présentent une hétérogénéité intrinsèque qui constitue un obstacle majeur à la reproductibilité des études multicentriques. Les différences entre constructeurs (Siemens, GE, Philips), les intensités de champ (1,5 T ou 3 T) et les paramètres de séquence (TR, TE, résolution spatiale) modifient la distribution des intensités et peuvent introduire des signaux non biologiques dans les caractéristiques extraites (Zwanenburg et al., 2020). Cette variabilité est particulièrement prégnante dans des cohortes comme I-SPY 2, où les données proviennent de multiples centres. Une étape de standardisation et de normalisation est donc nécessaire avant toute analyse quantitative.

1.2.2 Gestion des données médicales

Les données cliniques sont stockées au format DICOM, riche en métadonnées mais peu adapté aux traitements automatisés. Leur conversion en NIfTI est donc nécessaire, suivie d'une organisation structurée inspirée du standard BIDS, adaptée aux spécificités de l'IRM mammaire (séquences dynamiques, régions d'intérêt). Cette standardisation garantit la traçabilité et la reproductibilité des analyses.

1.2.3 Influence du prétraitement sur les caractéristiques radiomiques

Les caractéristiques radiomiques sont très sensibles aux opérations de prétraitement : le débruitage, la correction des inhomogénéités, la normalisation ou l'amélioration du contraste peuvent modifier la distribution des intensités et la texture, tout comme une segmentation imparfaite affecte les descripteurs de forme. Chaque choix méthodologique est donc susceptible d'introduire un biais et de

limiter la reproductibilité des études si ces étapes ne sont pas rigoureusement contrôlées et comparées (Traverso et al., 2018).

1.2.4 Besoin d’une pipeline modulaire et reproductible

Face à ces sources de variabilité, les approches manuelles ou les scripts expérimentaux ponctuels ne suffisent plus. Une pipeline moderne doit être **automatisée**, **modulaire** et **réutilisable**, afin de garantir la reproductibilité des analyses et de permettre une comparaison objective des méthodes de prétraitement via des métriques quantitatives (SNR, CNR, PSNR, SSIM) (Traverso et al., 2018).

Ainsi, la problématique centrale de ce travail se formule comme suit :

Comment concevoir une pipeline modulaire, automatisée et reproductible, appliquée aux images IRM de la cohorte I-SPY 2, capable d’évaluer objectivement l’influence des différentes méthodes de prétraitement sur la stabilité et la pertinence des caractéristiques radiomiques extraites ?

1.3 Intérêt de l’étude

L’exploitation quantitative des images IRM mammaires exige une préparation rigoureuse pour garantir la fiabilité des analyses. Le développement d’une pipeline structurée, automatisée et reproductible présente donc un intérêt à la fois scientifique, technique et applicatif.

1.3.1 Intérêt scientifique

Les caractéristiques radiomiques dépendent autant des propriétés biologiques des lésions que des conditions d’acquisition et de prétraitement. Leur variabilité, bien documentée, compromet la reproductibilité des études (Traverso et al., 2018). Ce projet s’aligne sur les recommandations de l’*Image Biomarker Standardisation Initiative* (IBSI) en évaluant systématiquement l’impact des méthodes de prétraitement, contribuant ainsi à des analyses plus robustes et comparables (Zwanenburg et al., 2020).

1.3.2 Intérêt technique

La pipeline automatise l’extraction des données depuis I-SPY 2, leur conversion DICOM/NIfTI, leur organisation selon une structure inspirée du standard BIDS et l’application de prétraitements modulaires. Cette architecture, associée à une bibliothèque dédiée, améliore la traçabilité et la reproductibilité par rapport aux scripts expérimentaux ponctuels (Gorgolewski et al., 2016). Elle facilite l’intégration de nouvelles méthodes et la comparaison objective des traitements.

1.3.3 Intérêt applicatif

En fournissant une infrastructure fiable pour la préparation et l'analyse quantitative des images IRM, cette étude constitue une base réutilisable pour de futurs travaux en oncologie, qu'il s'agisse de caractérisation tumorale, d'aide au diagnostic ou de développement de modèles d'intelligence artificielle.

1.4 Objectifs du projet

Face aux limites identifiées, ce projet vise à développer une pipeline modulaire, automatisée et reproductible pour l'analyse quantitative d'images IRM du cancer du sein, depuis l'extraction des données I-SPY 2 jusqu'à l'analyse statistique des caractéristiques radiomiques.

1.4.1 Objectif général

Concevoir une pipeline intégrant l'extraction, la conversion DICOM/NIfTI, l'organisation des données selon une structure inspirée de BIDS, l'application de méthodes de prétraitement modulables, l'extraction radiomique et l'évaluation statistique de l'impact du prétraitement.

1.4.2 Objectifs spécifiques

1. Extraction automatique des données du jeu I-SPY 2.
2. Conversion des images DICOM au format NIfTI.
3. Organisation des données selon une structure standardisée de type BIDS.
4. Conception d'une bibliothèque modulaire de prétraitement (correction d'intensité, normalisation, débruitage, amélioration de contraste, segmentation, etc.).
5. Extraction des caractéristiques radiomiques avec PyRadiomics.
6. Analyse statistique comparative de l'influence des prétraitements sur les caractéristiques.

Cette démarche s'inscrit dans les recommandations de l'IBSI pour améliorer la reproductibilité des biomarqueurs d'imagerie (Zwanenburg et al., 2020).

1.5 Revue de la littérature

Plusieurs standards et méthodes encadrent les pipelines d'analyse d'images médicales.

1.5.1 Formats et organisation des données

Les examens cliniques sont stockés au format **DICOM**, riche en métadonnées mais peu adapté aux traitements automatisés. Le format **NIfTI** est privilégié en recherche car il simplifie la manipulation

des volumes 3D/4D et s'intègre aux bibliothèques scientifiques (nibabel, SimpleITK) (Li et al., 2016). La conversion est réalisée avec des outils comme `dcm2niix`.

Pour garantir la reproductibilité, les données sont organisées selon le standard **BIDS** (*Brain Imaging Data Structure*), qui facilite le partage, la traçabilité et la validation automatique des architectures de fichiers (Gorgolewski et al., 2016). Dans ce projet, une organisation inspirée de BIDS est adaptée aux spécificités de l'IRM mammaire.

1.5.2 Méthodes de prétraitement et extraction radiomique

Les opérations de prétraitement (correction N4, normalisation Z-score, débruitage, CLAHE, etc.) influencent directement les caractéristiques radiomiques. Leur extraction est standardisée par des bibliothèques comme **PyRadiomics** et encadrée par l'**IBSI** (*Image Biomarker Standardisation Initiative*) qui définit des paramètres de calcul harmonisés (Zwanenburg et al., 2020).

1.5.3 Limites des approches existantes

Malgré ces avancées, la plupart des pipelines restent fragmentées et dépendantes de scripts expérimentaux, limitant la modularité et la comparaison systématique des stratégies de prétraitement. La reproductibilité des études multicentriques (notamment sur la cohorte I-SPY 2) demeure un enjeu majeur (Traverso et al., 2018). Ces lacunes motivent le développement d'une architecture modulaire intégrée, présentée ci-après.

1.5.4 Solution proposée

Pour répondre aux limites identifiées, ce projet développe une pipeline modulaire, automatisée et reproductible, couvrant l'ensemble du processus, de l'extraction des données I-SPY 2 à l'analyse statistique des caractéristiques radiomiques.

L'architecture s'articule autour de trois blocs (Figure 1.2) :

- **Extraction et organisation** : récupération automatique des examens, conversion DICOM/NIfTI et structuration selon un schéma inspiré de BIDS, garantissant la traçabilité des données.
- **Bibliothèque modulaire de prétraitement** : intégration de méthodes de correction d'intensité, normalisation, débruitage, amélioration du contraste, détection de contours, morphologie mathématique et segmentation, facilement extensible.
- **Extraction radiomique et analyse statistique** : utilisation de PyRadiomics pour extraire les caractéristiques (intensité, texture, forme), puis comparaison quantitative des stratégies de prétraitement via des indicateurs de qualité (SNR, CNR, ICC, etc.).




FIG. 1.2 : Architecture modulaire de la pipeline proposée.

Cette approche modulaire, extensible et réutilisable constitue une base méthodologique solide pour de futures études en analyse quantitative d'images mammaires.

Conclusion du chapitre

Ce chapitre a présenté le contexte et les enjeux de l'analyse quantitative des images IRM du cancer du sein. L'étude de la littérature a révélé un manque de standardisation globale, une modularité insuffisante des pipelines existants et une influence encore mal maîtrisée des prétraitements sur les caractéristiques radiomiques. Pour y répondre, une architecture modulaire, automatisée et reproductible a été proposée, intégrant l'extraction, l'organisation, le prétraitement et l'analyse statistique des données. Le chapitre suivant détaille les matériels et méthodes mis en œuvre pour sa réalisation.

CHAPITRE 2 Matériels et Méthodes

Ce chapitre présente la démarche méthodologique suivie pour concevoir et implémenter la pipeline modulaire de préparation et d'analyse d'images IRM du cancer du sein. Il détaille les ressources mobilisées, les choix techniques et les différentes étapes mises en œuvre, depuis l'extraction des données jusqu'à l'analyse statistique des caractéristiques radiomiques.

2.1 Présentation générale

La méthodologie adoptée repose sur une succession d'étapes complémentaires illustrées par la Figure 1.2 (chapitre précédent). Les examens IRM issus du jeu de données **I-SPY 2** sont extraits, convertis du format DICOM vers le format **NIfTI**, puis organisés selon une structure de données inspirée du standard **BIDS** (*Brain Imaging Data Structure*), adaptée à l'imagerie mammaire. Cette organisation garantit la traçabilité et la reproductibilité des traitements.

Une **bibliothèque modulaire de prétraitement** a été développée, intégrant plusieurs familles de méthodes : correction d'intensité, normalisation, débruitage, amélioration du contraste, détection de contours, morphologie mathématique et segmentation. Chaque méthode, implémentée comme un module indépendant, peut être utilisée seule ou combinée dans une chaîne de traitement flexible.

Les images prétraitées sont ensuite exploitées pour l'**extraction de caractéristiques radiomiques** à l'aide de **PyRadiomics**. Une **analyse statistique comparative** permet enfin d'évaluer l'influence des différentes stratégies de prétraitement sur la qualité et la stabilité des descripteurs extraits.

Les sections suivantes détaillent successivement les ressources matérielles et logicielles, la conception de la pipeline, les modules développés, les méthodes de prétraitement implémentées, le processus d'extraction radiomique et la méthodologie d'analyse statistique.

2.2 Matériels

Cette section décrit le jeu de données, l'organisation des fichiers et les environnements logiciel et matériel utilisés pour le développement et l'exécution de la pipeline.

2.2.1 Jeu de données I-SPY 2

L'étude s'appuie sur un sous-ensemble du jeu de données **I-SPY 2** (*Investigation of Serial Studies to Predict Your Therapeutic Response with Imaging And Molecular Analysis 2*), essai clinique multicentrique de phase II évaluant la réponse à la chimiothérapie néoadjuvante chez des patientes atteintes d'un cancer du sein localement avancé. Les données, obtenues via la plateforme *The Cancer Imaging Archive* (TCIA), comprennent des acquisitions IRM dynamiques avec injection de produit de contraste (DCE-MRI) et des images anatomiques T2/STIR au format DICOM. Les masques de segmentation tumorale ont été exploités lorsqu'ils étaient disponibles.

Un sous-ensemble représentatif a été sélectionné pour développer et valider les modules de la pipeline. Les informations cliniques (pCR, sous-types moléculaires) n'ont pas été utilisées, l'objectif étant centré sur l'impact des prétraitements sur les caractéristiques radiomiques.

TAB. 2.1 : Principales caractéristiques du jeu de données I-SPY 2.

Caractéristique	Description
Nom	I-SPY 2
Type d'étude	Essai clinique multicentrique de phase II
Pathologie	Cancer du sein localement avancé (stades II/III)
Source	The Cancer Imaging Archive (TCIA)
Modalité d'imagerie	IRM mammaire DCE et T2/STIR
Format d'origine	DICOM
Format de travail	NIfTI (.nii.gz)
Données exploitées	Images DCE, anatomiques, masques de segmentation
Données cliniques	Non utilisées




FIG. 2.1 : Illustration du jeu de données I-SPY 2 et des acquisitions IRM utilisées.

2.2.2 Organisation des données

Les examens sont structurés selon une hiérarchie inspirée du standard **BIDS** (*Brain Imaging Data Structure*). Chaque patiente dispose d'un répertoire contenant les sessions d'acquisition, et les fichiers NIfTI sont organisés par modalité avec une convention de nommage dérivée de BIDS. Les versions prétraitées sont stockées dans la même arborescence, un descripteur (*desc*) précisant la méthode appliquée.

Un script automatisé assure la conversion des descriptions de séries DICOM vers les suffixes BIDS, suivi d'une validation de conformité des noms générés.




FIG. 2.2 : Organisation des données selon une structure inspirée de BIDS.

2.2.3 Environnement de développement

La pipeline a été développée en **Python 3.10**, en s'appuyant sur les bibliothèques listées dans le Tableau 2.2. Les expérimentations ont été menées principalement sur **Google Colaboratory**, complété par un poste personnel pour le développement et les tests. Les dépendances sont consignées dans `requirements.txt`, les paramètres de prétraitement centralisés en YAML et l'exécution journalisée.

TAB. 2.2 : Principales bibliothèques logicielles utilisées.

Domaine	Bibliothèque	Rôle
Lecture DICOM	pydicom	Extraction des métadonnées.
Conversion	dcm2niix	DICOM vers NIfTI.
Manipulation NIfTI	nibabel	Lecture/écriture des volumes.
Traitement d'images	SimpleITK	Prétraitement et filtrage.
Calcul	NumPy, SciPy	Opérations numériques.
Vision	OpenCV, scikit-image	Contraste, segmentation, morphologie.
Radiomique	PyRadiomics	Extraction de caractéristiques.
Analyse	Pandas, SciPy/Statsmodels	Données tabulaires, tests statistiques.
Visualisation	Matplotlib, Seaborn	Graphiques.

2.2.4 Environnement matériel

Le développement a été réalisé sur un poste personnel sous Ubuntu Linux, tandis que les traitements expérimentaux ont été exécutés sur Google Colaboratory (version gratuite), qui fournit CPU, RAM et GPU selon disponibilité. Les méthodes de prétraitement classiques n'exigent pas de ressources spécialisées.

TAB. 2.3 : Environnement matériel utilisé.

Élément	Configuration
Environnement principal	Google Colaboratory
Langage	Python 3.10
Poste local	CPU multicœur, Ubuntu Linux
Accélération	GPU disponible (optionnel)
Stockage	Local + Google Drive

2.3 Conception de la pipeline

La conception de la pipeline repose sur une architecture modulaire, structurée en modules indépendants couvrant l'ensemble des traitements, depuis l'extraction des données jusqu'à l'analyse statistique. Cette approche garantit la flexibilité, la maintenabilité et la reproductibilité des expérimentations.

2.3.1 Architecture générale

La Figure ?? présentée précédemment illustre l'organisation générale de la pipeline développée. Cette architecture repose sur une succession de modules permettant de transformer les données IRM brutes issues de la cohorte I-SPY 2 en informations quantitatives exploitables pour l'analyse radiomique.

La conception adoptée suit une approche modulaire dans laquelle chaque bloc fonctionnel correspond à une étape spécifique du traitement. Cette organisation permet de séparer les différentes opérations, de faciliter leur comparaison et d'assurer la traçabilité des transformations appliquées aux images.

2.3.2 Architecture logicielle et packages

La pipeline est implémentée sous la forme d'un package Python nommé `breast_mri_pipeline`, organisé en sous-packages reflétant les étapes fonctionnelles :

- `pipeline.data_extraction` : extraction des données depuis TCIA et préparation initiale ;
- `pipeline.conversion` : conversion des séries DICOM vers le format NIfTI ;
- `pipeline.organization` : structuration des fichiers selon l'arborescence inspirée de BIDS ;
- `pipeline.preprocessing` : bibliothèque modulaire de prétraitement (correction, normalisation, débruitage, etc.) ;
- `pipeline.radiomics` : extraction des caractéristiques radiomiques via PyRadiomics ;
- `pipeline.statistics` : analyse statistique comparative et visualisation.

Chaque sous-package expose une interface standardisée (une classe ou une fonction principale) permettant de l'exécuter indépendamment ou de l'intégrer dans un script orchestrant l'ensemble du flux. Les paramètres de configuration sont chargés à partir de fichiers YAML, et les logs sont centralisés pour assurer la traçabilité.

2.3.3 Principes architecturaux et choix de conception

Plusieurs principes ont guidé la conception de la pipeline :

1. **Modularité** : chaque traitement est encapsulé dans un module autonome, facilitant l'ajout, le remplacement ou la comparaison de méthodes.
2. **Reproductibilité** : l'utilisation de fichiers de configuration YAML, la journalisation systématique et le respect d'une arborescence normalisée (BIDS) garantissent la reproductibilité des expériences.
3. **Extensibilité** : de nouvelles méthodes de prétraitement ou d'extraction peuvent être intégrées sans modifier le reste de la chaîne, simplement en implémentant une interface commune.
4. **Portabilité** : la pipeline est compatible avec un environnement Python standard et peut s'exécuter aussi bien sur un poste local que sur une plateforme cloud comme Google Colab.
5. **Séparation des préoccupations** : les étapes de traitement, d'analyse et de visualisation sont clairement séparées, ce qui améliore la lisibilité et la maintenance du code.

Ces choix architecturaux ont permis de développer une solution à la fois robuste pour l'étude en cours et adaptable à d'autres jeux de données d'imagerie médicale.

2.4 Modules de la pipeline

La pipeline est décomposée en modules indépendants couvrant l'extraction, la conversion, l'organisation et le prétraitement des données. Cette modularité facilite la maintenance, la réutilisation et la comparaison des traitements.

2.4.1 Extraction des données

Le module d'extraction, intégré au package **DATAUTILS**, automatise la récupération des données I-SPY 2 depuis les serveurs TCIA/NBIA. Il sélectionne un sous-ensemble de patientes selon des critères définis, identifie les sessions d'acquisition IRM pertinentes, télécharge les séries DICOM correspondantes et organise les fichiers localement. Les paramètres d'échantillonnage (taille, graine aléatoire) sont contrôlés pour assurer la reproductibilité.

2.4.2 Conversion DICOM → NIfTI

Les séries DICOM extraites sont converties au format NIfTI à l'aide de **dicom2nifti**. Un contrôle qualité automatisé, via **NiBabel**, vérifie l'intégrité des volumes : dimensions, orientation spatiale, matrice affine et résolution voxel. Une structure **MedicalImage3D** encapsule chaque volume avec ses métadonnées et masques associés, standardisant ainsi la manipulation des images dans les modules suivants.

2.4.3 Organisation des données selon BIDS

Les volumes NIfTI sont organisés selon une hiérarchie inspirée de **BIDS** (Figure 2.2), avec des répertoires par sujet et session. Les images originales, prétraitées et les résultats d'analyse sont stockés dans des espaces distincts (notamment un dossier **derivatives**), garantissant la traçabilité complète des transformations et facilitant l'intégration de nouveaux traitements.

2.4.4 Bibliothèque de prétraitement

Ce module central regroupe, dans une architecture logicielle unifiée, les méthodes appliquées avant extraction radiomique. Il est structuré en quatre sous-modules :

- **Correction et normalisation des intensités** : N4ITK, Min-Max, Z-score, méthodes robustes.
- **Réduction du bruit** : filtre gaussien, diffusion anisotrope, Non-Local Means adapté au bruit Rician.
- **Amélioration du contraste** : égalisation d'histogramme, CLAHE, correction gamma.
- **Analyse morphologique** : opérations d'érosion, dilatation, ouverture/fermeture, segmentation.

Chaque méthode peut être exécutée indépendamment ou intégrée dans un flux complet. L'implémentation repose sur **SimpleITK**, **scikit-image**, **SciPy** et **NiBabel**.

2.5 Méthodes de prétraitement

Les images IRM présentent des variabilités liées aux acquisitions, aux champs magnétiques et aux équipements. La bibliothèque modulaire développée regroupe plusieurs familles de prétraitement appliquées avant extraction radiomique. Chaque méthode est encapsulée dans un module indépendant, facilitant la comparaison des stratégies.

2.5.1 Correction d'intensité et normalisation

Correction du champ de biais N4ITK

L'inhomogénéité du champ magnétique est corrigée par l'algorithme N4ITK, qui estime le champ de biais multiplicatif $B(x)$ dans le modèle :

$$I(x) = J(x) \times B(x) + \epsilon(x) \quad (2.1)$$

où $J(x)$ est l'image corrigée.

Normalisation Min-Max

$$I_{\text{norm}}(x) = \frac{I(x) - I_{\min}}{I_{\max} - I_{\min}} \quad (2.2)$$

Version robuste utilisant des percentiles P_{low} et P_{high} au lieu des extrema.

Normalisation Z-score

$$I_{\text{norm}}(x) = \frac{I(x) - \mu}{\sigma} \quad (2.3)$$

Variante robuste utilisant médiane et écart interquartile.

Median-MAD scaling

$$I_{\text{norm}}(x) = \frac{I(x) - \text{Median}(I)}{\text{MAD}(I)}, \quad \text{MAD}(I) = \text{Median}(|I - \text{Median}(I)|) \quad (2.4)$$

Modèle de mélange gaussien (GMM)

La distribution des intensités est modélisée par K composantes gaussiennes :

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \sigma_k^2) \quad (2.5)$$

TAB. 2.4 : Comparaison des méthodes de correction d'intensité et de normalisation

Méthode	Principe	Avantage principal
N4ITK	Correction du champ de biais	Homogénéité spatiale
Min-Max	Projection dans un intervalle	Conservation de la distribution relative
Min-Max robuste	Percentiles au lieu des extrema	Robuste aux outliers
Z-score	Centrage-réduction	Adapté au ML
Z-score robuste	Estimateurs robustes	Stabilité face aux valeurs extrêmes
Median-MAD	Médiane et MAD	Très résistant aux outliers
GMM	Modélisation probabiliste	Représentation multi-classes

2.5.2 Amélioration du contraste

Égalisation d'histogramme (HE)

Redistribution globale des intensités selon la fonction de répartition cumulative :

$$s = T(r) = (L - 1) \sum_{i=0}^r p(i) \quad (2.6)$$

CLAHE

Égalisation adaptative locale avec limitation du contraste via un seuil de clipping.

Correction gamma

$$I_{\text{out}} = I_{\text{in}}^\gamma \quad (2.7)$$

TAB. 2.5 : Comparaison des méthodes d'amélioration du contraste

Méthode	Principe	Caractéristique
HE	Redistribution globale	Améliore le contraste global
CLAHE	Égalisation locale limitée	Réduit l'amplification du bruit
Correction gamma	Transformation non linéaire	Contrôle flexible de la luminosité

2.5.3 Réduction du bruit

Filtre gaussien

Lissage par convolution avec un noyau gaussien 3D d'écart-type σ .

Diffusion anisotrope de Perona-Malik

Équation de diffusion préservant les contours :

$$\frac{\partial I}{\partial t} = \nabla \cdot (c(|\nabla I|)\nabla I) \quad (2.8)$$

Non-Local Means adapté au bruit Rician

Moyenne pondérée des pixels similaires (patches) :

$$NL[I](x) = \sum_y w(x, y)I(y) \quad (2.9)$$

TAB. 2.6 : Comparaison des méthodes de réduction du bruit

Méthode	Principe	Avantage
Filtre gaussien	Convolution gaussienne	Simple et rapide
Diffusion anisotrope	Diffusion conditionnée par le gradient	Préserve les contours
Non-Local Means	Similarité de patches	Adapté au bruit Rician

2.5.4 Détection de contours

Sobel

Gradient spatial :

$$|\nabla I| = \sqrt{G_x^2 + G_y^2} \quad (2.10)$$

Canny

Étapes : lissage gaussien, gradient, suppression des non-maxima, seuillage par hystérésis.

TAB. 2.7 : Comparaison des méthodes de détection de contours

Méthode	Principe	Propriété
Sobel	Gradient spatial	Simple et rapide
Canny	Gradient + hystérésis	Contours fins et robustes

2.5.5 Morphologie mathématique

Opérations binaires utilisant un élément structurant B :

- Érosion : $A \ominus B = \{x \mid B_x \subseteq A\}$ (réduction)
- Dilatation : $A \oplus B = \{x \mid B_x \cap A \neq \emptyset\}$ (expansion)
- Ouverture : $A \circ B = (A \ominus B) \oplus B$ (suppression du bruit)
- Fermeture : $A \bullet B = (A \oplus B) \ominus B$ (remplissage des trous)

- Reconstruction morphologique : restauration des structures connectées
- Gradient morphologique : $G_m = (A \oplus B) - (A \ominus B)$

Des fonctions utilitaires sont également disponibles : suppression de petits objets, remplissage de trous, extraction de la plus grande composante connexe, calcul de caractéristiques de forme.

TAB. 2.8 : Synthèse des opérations morphologiques implémentées

Opération	Effet	Application
Érosion	Réduction	Suppression des petites structures
Dilatation	Expansion	Comblement des discontinuités
Ouverture	Érosion + dilatation	Suppression du bruit ponctuel
Fermeture	Dilatation + érosion	Remplissage des trous
Reconstruction	Restauration contrôlée	Conservation des structures connectées
Gradient morph.	Différence dilatation/érosion	Extraction des contours

2.5.6 Segmentation des régions d'intérêt

Otsu

Seuillage automatique maximisant la variance interclasse.

Watershed

Ligne de partage des eaux sur le gradient morphologique.

Active Contours (Snakes)

Énergie : $E(C) = E_{\text{int}}(C) + E_{\text{ext}}(C)$

Level Set

Évolution d'une fonction implicite $\phi : \frac{\partial \phi}{\partial t} + F|\nabla \phi| = 0$

Region Growing

Croissance de région depuis des graines selon un critère d'homogénéité.

K-Means

Classification non supervisée minimisant la somme des distances intra-classe.

Atlas-based segmentation

Recalage d'un volume de référence avec SimpleITK.

TAB. 2.9 : Comparaison des méthodes de segmentation

Méthode	Principe	Avantage
Otsu	Seuillage automatique	Simple et rapide
Watershed	Ligne de partage des eaux	Bonne séparation des régions
Active Contours	Contours évolutifs	Formes irrégulières
Level Set	Fonction implicite	Changements topologiques
Region Growing	Expansion depuis graines	Contrôle local
K-Means	Classification non supervisée	Distribution des intensités
Atlas-based	Recalage d'un atlas	Connaissance a priori

2.5.7 Post-traitement et évaluation des masques

Nettoyage

Suppression des petits objets, extraction de la plus grande composante connexe, remplissage des trous.

Métriques d'évaluation

Lorsque des masques de référence sont disponibles :

- Dice : $\frac{2|A \cap B|}{|A| + |B|}$
- IoU : $\frac{|A \cap B|}{|A \cup B|}$
- Sensibilité = $\frac{TP}{TP+FN}$, Spécificité = $\frac{TN}{TN+FP}$, Précision = $\frac{TP}{TP+FP}$
- Distance de Hausdorff 95 : écart spatial entre frontières
- Similarité volumique : $1 - \frac{|A-B|}{|A|+|B|}$

TAB. 2.10 : Synthèse des opérations de post-traitement et métriques

Élément	Rôle
Suppression petits objets	Réduction du bruit dans les masques
Composante connexe principale	Conservation de la région principale
Remplissage des trous	Continuité des régions
Dice, IoU, Sensibilité, Spécificité, Précision	Chevauchement et classification
Hausdorff95	Précision géométrique
Similarité volumique	Comparaison des volumes

Synthèse de la section

La bibliothèque de prétraitement intègre 7 méthodes de correction/normalisation, 4 méthodes d'amélioration du contraste, 3 filtres de débruitage, 2 détecteurs de contours, une gamme d'opérateurs morphologiques, 7 stratégies de segmentation et des outils d'évaluation. Cette modularité permet une analyse systématique de l'impact du prétraitement sur les caractéristiques radiomiques.

2.6 Extraction des caractéristiques radiomiques

Après prétraitement et segmentation, les volumes IRM sont exploités pour extraire des caractéristiques quantitatives (radiomique). Cette étape vise à produire des descripteurs objectifs et reproductibles, permettant d'étudier l'influence des prétraitements sur les propriétés des images I-SPY 2.

L'extraction utilise la bibliothèque **PyRadiomics**, conforme aux recommandations de l'*Image Biomarker Standardisation Initiative* (IBSI).

2.6.1 Principe et utilisation de PyRadiomics

Le processus d'extraction suit les étapes suivantes :

1. lecture du volume NIFTI et du masque de segmentation ;
2. rééchantillonnage à une résolution uniforme (si nécessaire) ;
3. discrétisation des niveaux de gris (paramètres IBSI) ;
4. calcul des caractéristiques réparties en plusieurs familles ;
5. export des résultats au format CSV.

La Figure 2.3 illustre ce flux.

Image IRM prétraitée → Masque de segmentation → Rééchantillonnage →
Discrétisation → PyRadiomics → Caractéristiques → Fichier CSV

FIG. 2.3 : Principe général de l'extraction radiomique avec PyRadiomics.

2.6.2 Catégories de caractéristiques radiomiques

PyRadiomics calcule plusieurs familles de caractéristiques décrivant la morphologie, l'intensité et la texture de la région d'intérêt.

- **First Order** : statistiques de l'histogramme des intensités (moyenne, variance, entropie, etc.).
- **Shape** : géométrie 3D (volume, surface, sphéricité, compacité, élongation).
- **GLCM** (*Grey Level Co-occurrence Matrix*) : relations entre paires de voxels voisins (contraste, corrélation, homogénéité).
- **GLRLM** (*Grey Level Run Length Matrix*) : longueur des séries de voxels de même intensité (Short Run Emphasis, etc.).
- **GLSZM** (*Grey Level Size Zone Matrix*) : taille des zones homogènes (Zone Entropy, Large Area Emphasis).
- **GLDM** (*Grey Level Dependence Matrix*) : dépendance locale entre intensités (Dependence Entropy).

- **NGTDM** (*Neighbouring Gray Tone Difference Matrix*) : différences avec le voisinage immédiat (Coarseness, Busyness, Complexity).

TAB. 2.11 : Principales familles de caractéristiques radiomiques extraites.

Famille	Description	Exemples
First Order	Distribution des intensités	Mean, Variance, Entropy
Shape	Morphologie 3D	Volume, Surface, Sphericity
GLCM	Co-occurrence des gris	Contrast, Correlation, Homogeneity
GLRLM	Longueur de séries	Short Run Emphasis
GLSZM	Taille de zones	Zone Entropy
GLDM	Dépendances locales	Dependence Entropy
NGTDM	Différences au voisinage	Coarseness, Busyness

Ces caractéristiques constituent les variables quantitatives utilisées dans l'analyse statistique comparative (section suivante).

2.7 Analyse statistique

Afin d'évaluer l'influence des méthodes de prétraitement sur les caractéristiques radiomiques, une analyse statistique est menée en deux temps : d'abord une description de la qualité et de la stabilité des variables, puis une comparaison des méthodes.

2.7.1 Indicateurs de qualité et de stabilité

La première phase consiste à caractériser la distribution des caractéristiques extraites pour chaque méthode de prétraitement. Les indicateurs statistiques descriptifs utilisés sont résumés dans le Tableau 2.12. Des visualisations (histogrammes, boîtes à moustaches) complètent l'analyse. Une caractéristique est jugée stable si elle varie peu d'une méthode de prétraitement à l'autre.

TAB. 2.12 : Indicateurs de qualité et de stabilité des caractéristiques radiomiques

Indicateur	Objectif
Moyenne, médiane	Tendance centrale (robuste pour la médiane).
Écart-type	Dispersion autour de la moyenne.
Minimum, maximum, quartiles	Étendue et répartition des données.
Histogrammes	Distribution des caractéristiques.
Boxplots	Comparaison des dispersions et détection de valeurs aberrantes.
Matrices de corrélation	Relations entre caractéristiques.

2.7.2 Tests statistiques et comparaison des méthodes

La seconde phase compare les distributions des caractéristiques obtenues après les différents prétraitements (correction, normalisation, débruitage, amélioration de contraste, morphologie, segmentation).

L’objectif est d’identifier les méthodes qui préservent le mieux l’information quantitative, en s’appuyant sur des tests statistiques adaptés (implémentés avec `SciPy`, `Pandas`, etc.). Le Tableau 2.13 synthétise les questions abordées.

TAB. 2.13 : Objectifs de la comparaison statistique

Aspect étudié		Objectif
Distribution caractéristiques	des	Influence des prétraitements sur les valeurs radiomiques.
Variabilité caractéristiques	des	Stabilité et reproductibilité des variables.
Comparaison méthodes	entre	Identification des méthodes les plus robustes.
Corrélations entre variables		Relations entre les différentes caractéristiques.

Cette analyse permet de sélectionner les stratégies de prétraitement offrant le meilleur compromis entre stabilité et préservation de l’information, avant l’exploitation des résultats dans le chapitre suivant.

Conclusion du chapitre

Ce chapitre a détaillé les matériels et les méthodes utilisés : extraction des données I-SPY 2, conversion DICOM/NIfTI, organisation selon un schéma inspiré de BIDS, bibliothèque modulaire de prétraitement (correction, normalisation, débruitage, contraste, segmentation, etc.) et extraction standardisée des caractéristiques radiomiques via `PyRadiomics`. La méthodologie d’analyse statistique a également été définie pour évaluer l’impact des prétraitements. Le chapitre suivant présente les résultats expérimentaux et leur discussion.